CQA

Контроль качества поддержки, которому можно верить

Журнал контроля для Freedom Broker

с1 контакт · с2 потребность · с3 идентификация · с4 консультация · с5 эмпатия · с6 ведение · с7 завершение · с8 грубые · с1 контакт · с2 потребность · с3 идентификация · с4 к

LLM-судья предвзят. Это *измерено*

01

Позиционный

Порядок ступеней шкалы и вариантов сдвигает ответ

Wang, arXiv 2305.17926

EMNLP 2026

02

На длину

Длинный и гладкий ответ нравится судье больше

MT-Bench

arXiv 2306.05685

03

Нестабильность

Один и тот же вход, разные решения. А повтор бывает «стабильно, но неверно»

Kili 2026

04

Потолок людей

Эксперты между собой согласны на к ≈ 0,80

NVIDIA

arXiv 2510.09738

κ

0,80

эксперты между собой

NVIDIA, arXiv 2510.09738

Цель архитектуры

Стабильно.
Честно.

Стабильно: тот же диалог, тот же балл

Честно: каждое снижение доказано репликой

парное сравнение

A	B	ничья

перекос переезжает в ступени шкалы

наша рубрика: 8 критериев с весами

c1	c2	c3	c4	c5	c6	c7	c8
10	15	20	20	15	15	5	флаг
Контакт	Потребность	Идентификация	Консультация	Эмпатия	Ведение	Завершение	Грубые

#12 подсказка критерия: снижение только с номером реплики

85,00 → 80,50 на *одном* и том же чате

p1-en-006 «Ведение диалога», шкала 10 / 7 / 4 / 0

	прогон 1	прогон 2
Судья A	10	10
Судья B	7	7
Арбитр	10	7
Итог	~~85,00~~	80,50

95 из 96

ответов совпали на повторном прогоне

κ 0,96

согласие с эталоном на 10 новых чатах

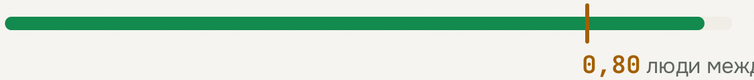

новый слой

Проверка согласованности

- Кеш: тот же текст и чек-лист дают тот же ответ без нового вызова
- Арбитр обязателен при любом споре по шкале
- Нет сбоя с номером реплики, нет снижения

RTX 5070 Ti, 8 ГБ, *бесплатно*

сценарий 1

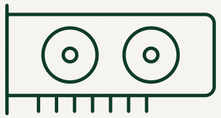

модель, помещается в 8 ГБ	точность против эталона, %	RU / KZ / EN
Gemma 4 26B-A4B	**83,9**	88 / 81 / 78
gpt-oss-20b	70,1	70 / 71 / 70
Granite 4.2 8B	66,7	63 / 62 / 78
Ministral 8B	62,1	67 / 52 / 61
Qwen 3.5 9B	61,6	50 / 76 / 69

данные не выходят из контура, 84% для режима без интернета

Облако: *цена* и точность

сценарий 2 · 16 моделей · 12 размеченных чатов · на графике 11 облачных

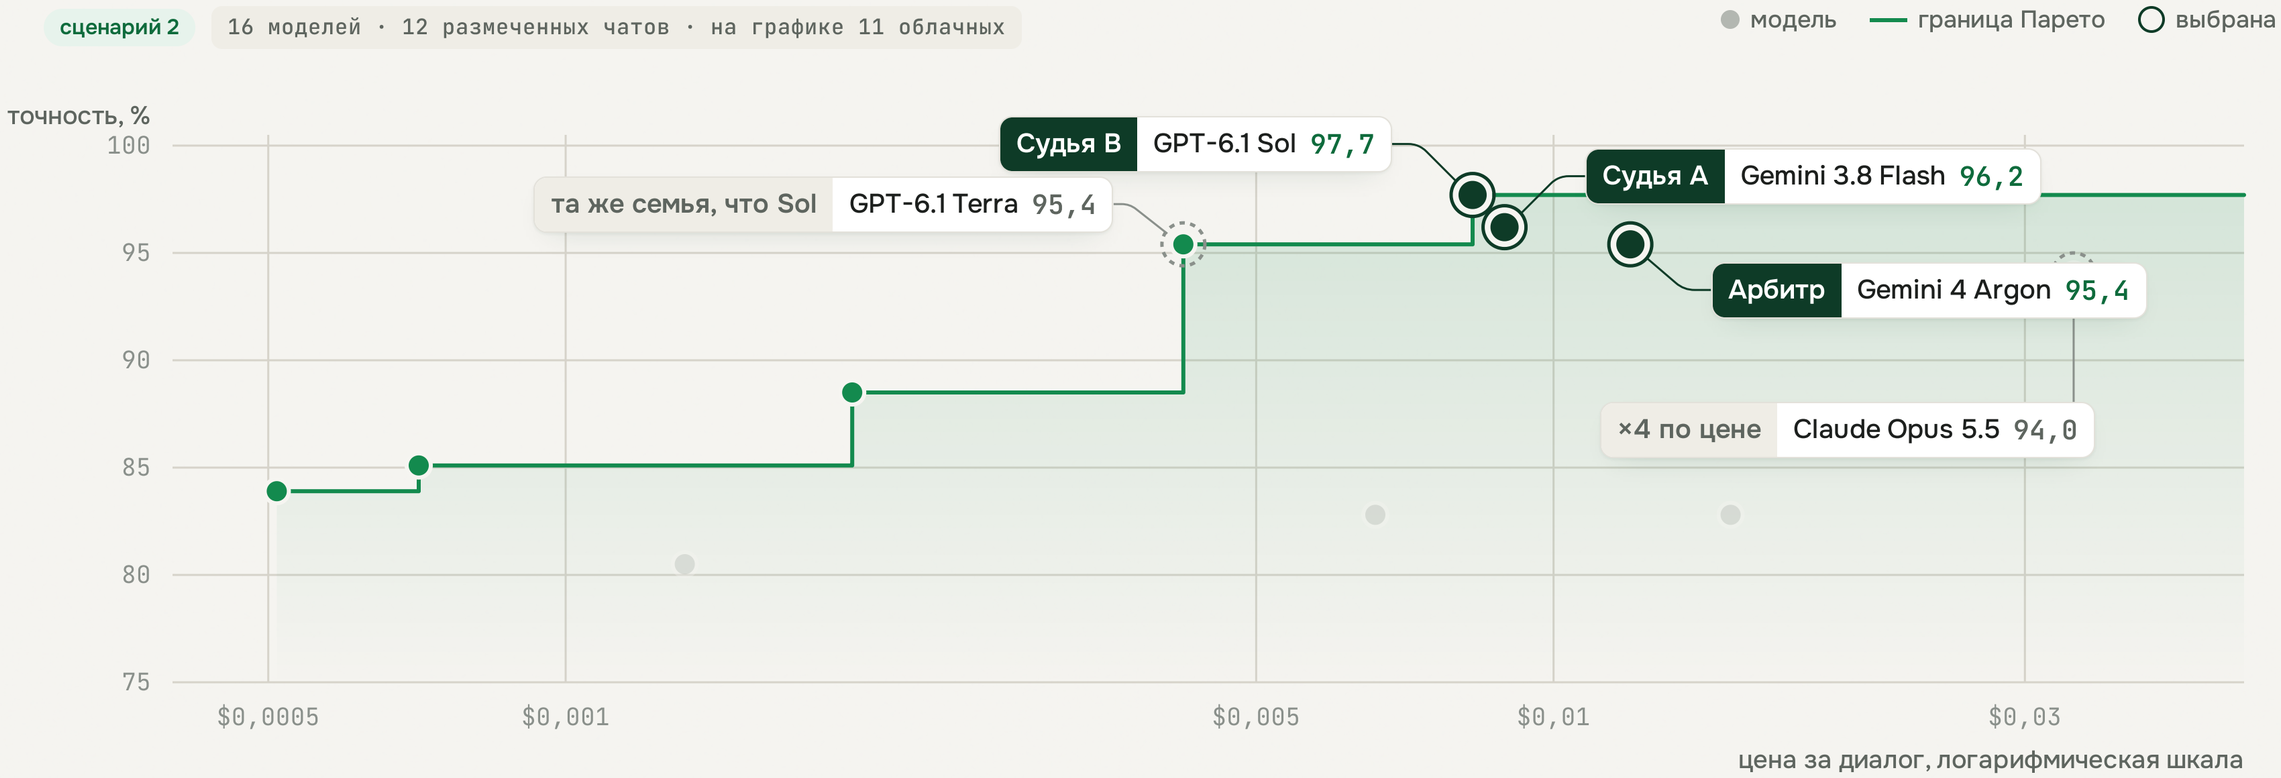

$0,021 за диалог: два судьи и арбитр

83 с на 10 чатов, лучший прогон

Не «скормили LLM»: *конвейер*

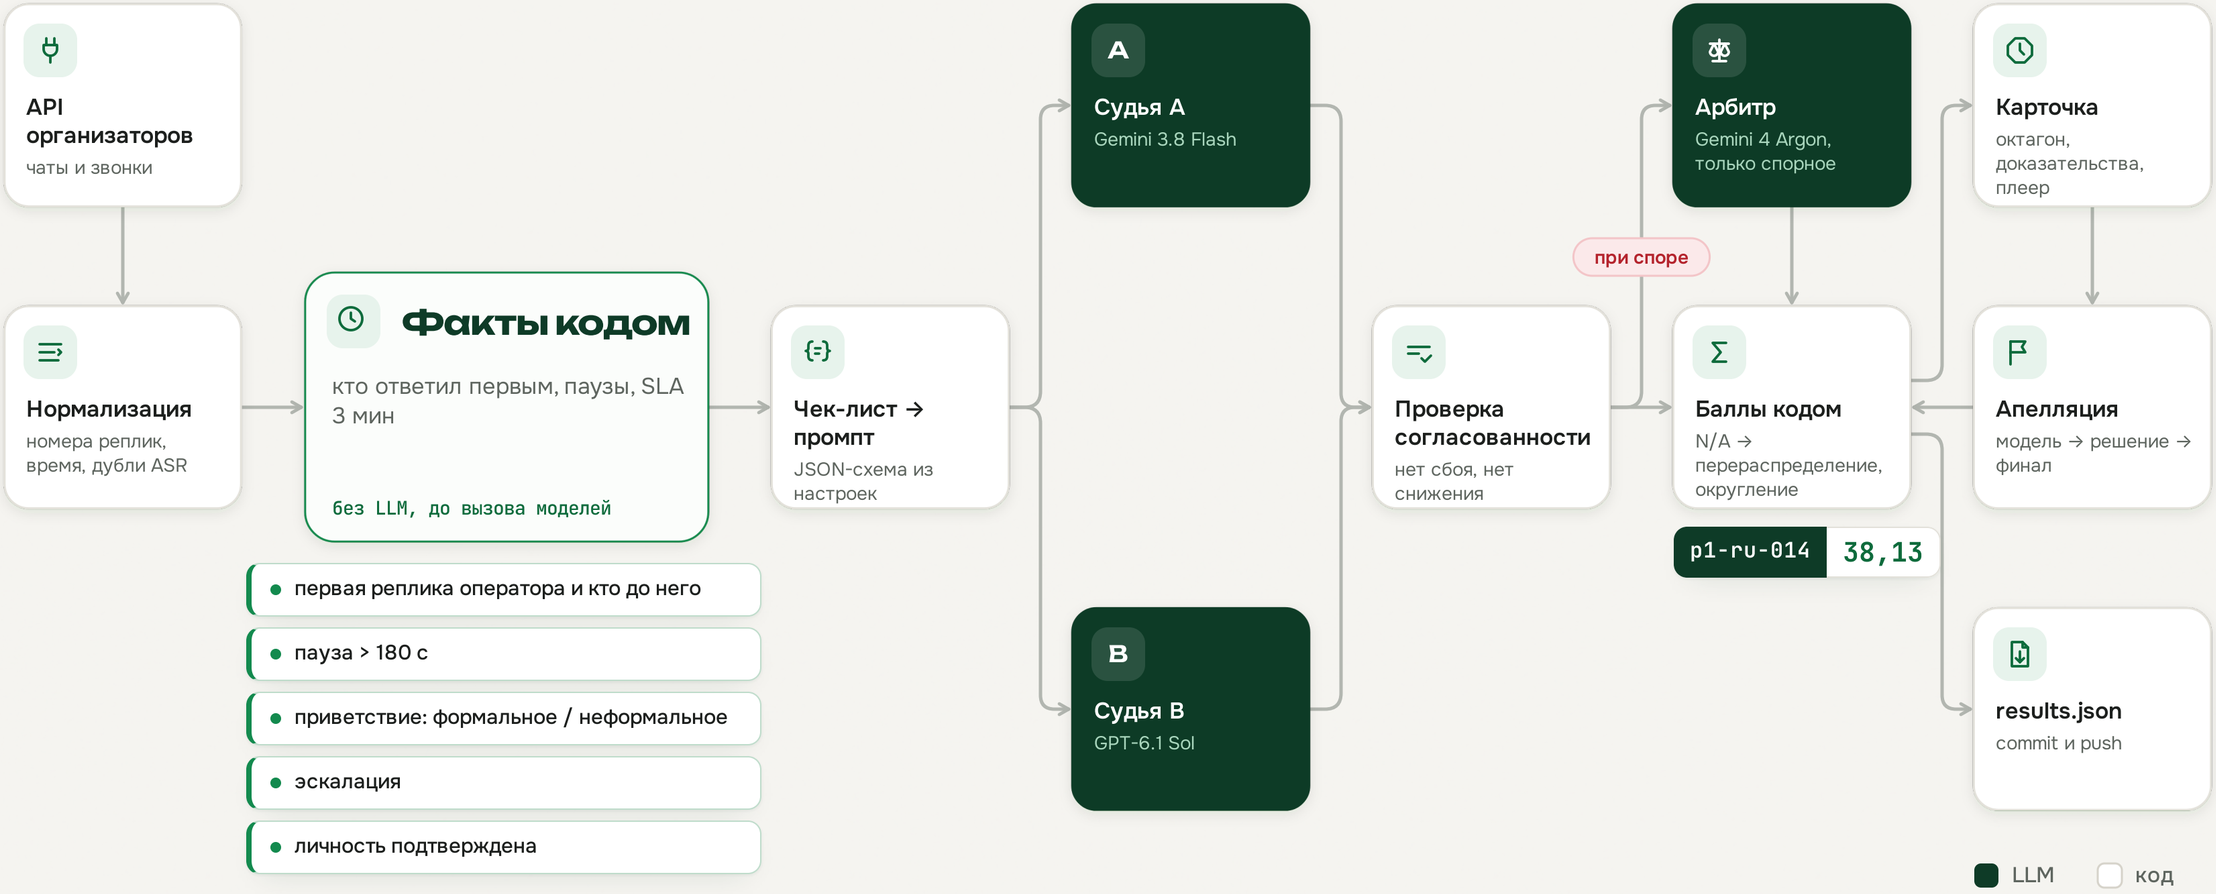

Пример ru-014 поддержка решила вопрос клиента

38,13 из 100

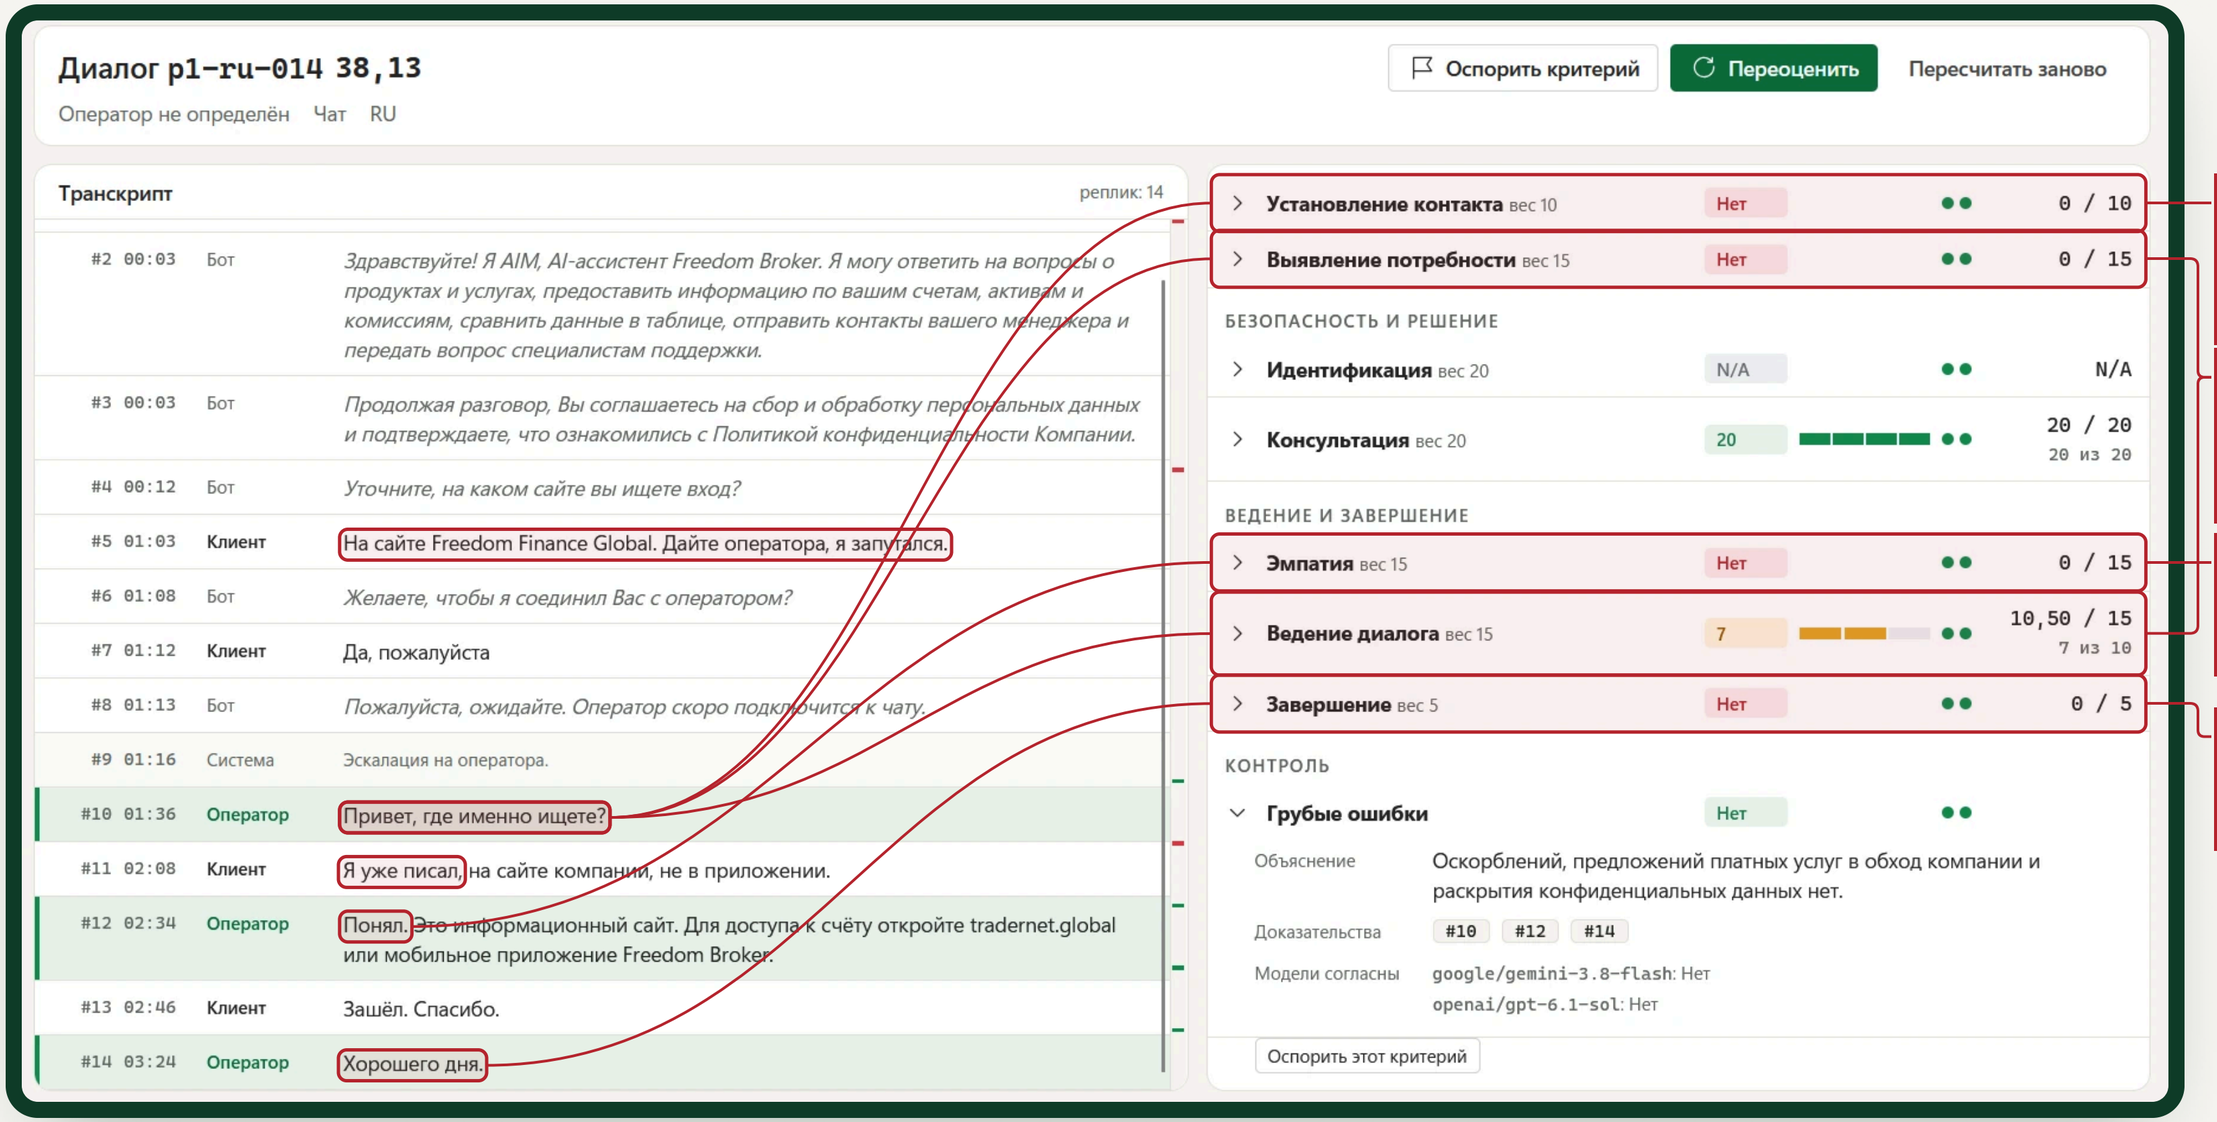

Диалог p1-ru-014 38,13

Оператор не определён Чат RU

Оспорить критерий | Переоценить | Пересчитать заново

Транскрипт

реплик: 14

#2 00:03	Бот	*Здравствуйте! Я AIM, AI-ассистент Freedom Broker. Я могу ответить на вопросы о продуктах и услугах, предоставить информацию по вашим счетам, активам и комиссиям, сравнить данные в таблице, отправить контакты вашего менеджера и передать вопрос специалистам поддержки.*
#3 00:03	Бот	*Продолжая разговор, Вы соглашаетесь на сбор и обработку персональных данных и подтверждаете, что ознакомились с Политикой конфиденциальности Компании.*
#4 00:12	Бот	*Уточните, на каком сайте вы ищете вход?*
#5 01:03	Клиент	На сайте Freedom Finance Global. Дайте оператора, я запутался.
#6 01:08	Бот	*Желаете, чтобы я соединил Вас с оператором?*
#7 01:12	Клиент	Да, пожалуйста
#8 01:13	Бот	*Пожалуйста, ожидайте. Оператор скоро подключится к чату.*
#9 01:16	Система	Эскалация на оператора.
#10 01:36	Оператор	Привет, где именно ищете?
#11 02:08	Клиент	Я уже писал, на сайте компании, не в приложении.
#12 02:34	Оператор	Понял. Это информационный сайт. Для доступа к счёту откройте tradernet.global или мобильное приложение Freedom Broker.
#13 02:46	Клиент	Зашёл. Спасибо.
#14 03:24	Оператор	Хорошего дня.

Установление контакта вес 10	Нет	●●	0 / 10
Выявление потребности вес 15	Нет	●●	0 / 15
БЕЗОПАСНОСТЬ И РЕШЕНИЕ			
Идентификация вес 20	N/A	●●	N/A
Консультация вес 20	20	●●	20 / 20 20 из 20
ВЕДЕНИЕ И ЗАВЕРШЕНИЕ			
Эмпатия вес 15	Нет	●●	0 / 15
Ведение диалога вес 15	7	●●	10,50 / 15 7 из 10
Завершение вес 5	Нет	●●	0 / 5
КОНТРОЛЬ			
Грубые ошибки	Нет	●●	

Объяснение: Оскорблений, предложений платных услуг в обход компании и раскрытия конфиденциальных данных нет.

Доказательства: #10 #12 #14

Модели согласны: google/gemini-3.8-flash: Нет; openai/gpt-6.1-sol: Нет

Оспорить этот критерий

Контакт: Нет

«Привет», имени нет; флаг неформального приветствия

#10

Потребность: Нет, Ведение: 7

переспросил то, что клиент уже сказал

#5 → #10

Эмпатия: Нет

«Понял» в ответ на «Я уже писал»

#11 → #12

Завершение: Нет

«Хорошего дня» без итога

#14

Пример ru-015 тот же тип вопроса

38,13 p1-ru-014 **92,31** p1-ru-015

разница 54 балла, каждое снижение со ссылкой на реплику

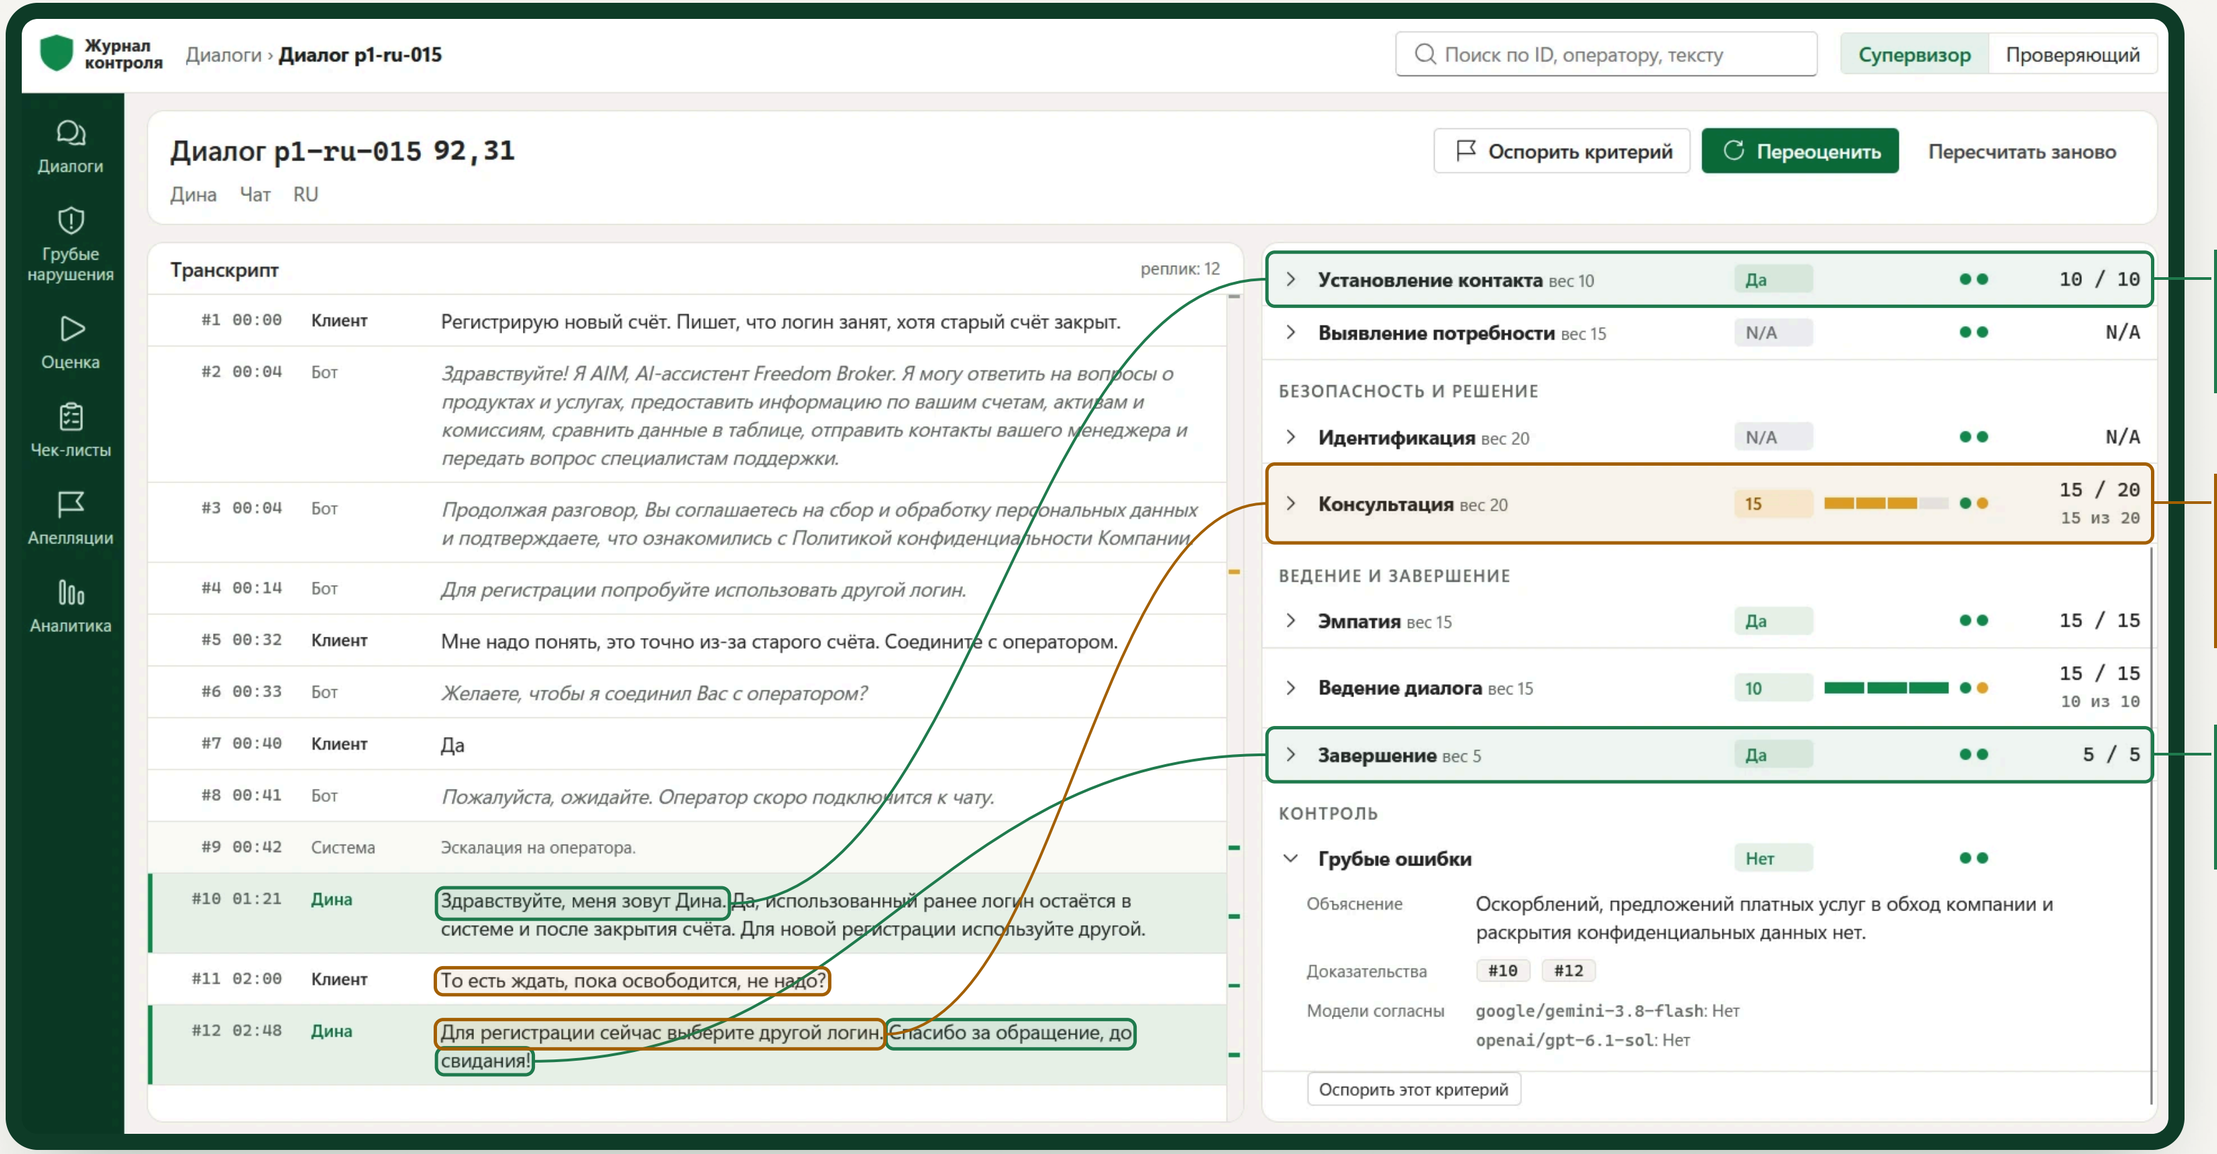

Контакт: Да

«Здравствуйте, меня зовут Дина»

#10

Консультация: 15 из 20

на «ждать не надо?» нет прямого ответа

#11 → #12

Завершение: Да

благодарность и прощание

#12

Два судьи и *арбитр*

Судья A — Google

Gemini 3.8 Flash

KZ
100%

Судья B — OpenAI

GPT-6.1 Sol

EN
100%

грубые
12/12

Арбитр — только спорные критерии

Gemini 4 Argon

на контроле
2 из 80

код **баллы считает код: N/A перераспределяет вес, округление half-up**

точность на 10 новых чатах
97,2%
69 из 71

ошибка итога
4,30
баллов из 100

стабильность повтора
99%
95 из 96

за диалог
$0,021
два судьи и арбитр

Живое демо ›

github.com/GeorgeTolen/real-couple

резерв

Все 16 моделей

Модель	Точность	RU	KZ	EN	Грубые	Ошибка итога	$ за диалог	с на диалог	8 ГБ	Роль
GPT-6.1 Sol	97,7	98	95	100	12/12	5,71	0,00828	9,2		**Судья B**
Gemini 3.8 Flash	96,2	97	100	91	10/11	2,97	0,00892	15,9		**Судья A**
GPT-6.1 Terra	95,4	93	100	96	12/12	9,58	0,00422	9,3		
Gemini 4 Argon	95,4	98	95	91	12/12	4,86	0,01196	13,4		**Арбитр**
Claude Opus 5.5	94,0	93	100	94	9/9	2,85	0,03361	13,9		
DeepSeek V4.1 Flash	88,5	88	86	91	12/12	10,29	0,00195	13,7		
GPT-6 Luna	85,1	86	81	87	12/12	10,16	0,00071	14,3		
GLM-5.3 Flash	83,9	79	81	96	12/12	8,83	0,00051	6		
Gemma 4 26B-A4B	83,9	88	81	78	11/12	11,18	0,00036	15	да	**Локально**
Claude Sonnet 5.5	82,8	81	81	87	11/12	11,22	0,01511	9		
Qwen3.8 27B	82,8	81	76	91	12/12	16,27	0,0066	25		
Claude Haiku 5.5	80,5	81	81	78	12/12	14,80	0,00132	10,2		
gpt-oss-20b	70,1	70	71	70	11/12	17,43	0,0002	8,2	да	
Granite 4.2 8B	66,7	63	62	78	10/12	16,60	0,0002	7,5	да	
Ministral 8B	62,1	67	52	61	10/12	24,20	0,00031	9,4	да	
Qwen 3.5 9B	61,6	50	76	69	9/10	31,10	0,00021	157,5	да	

резерв

Звонок и Whisper

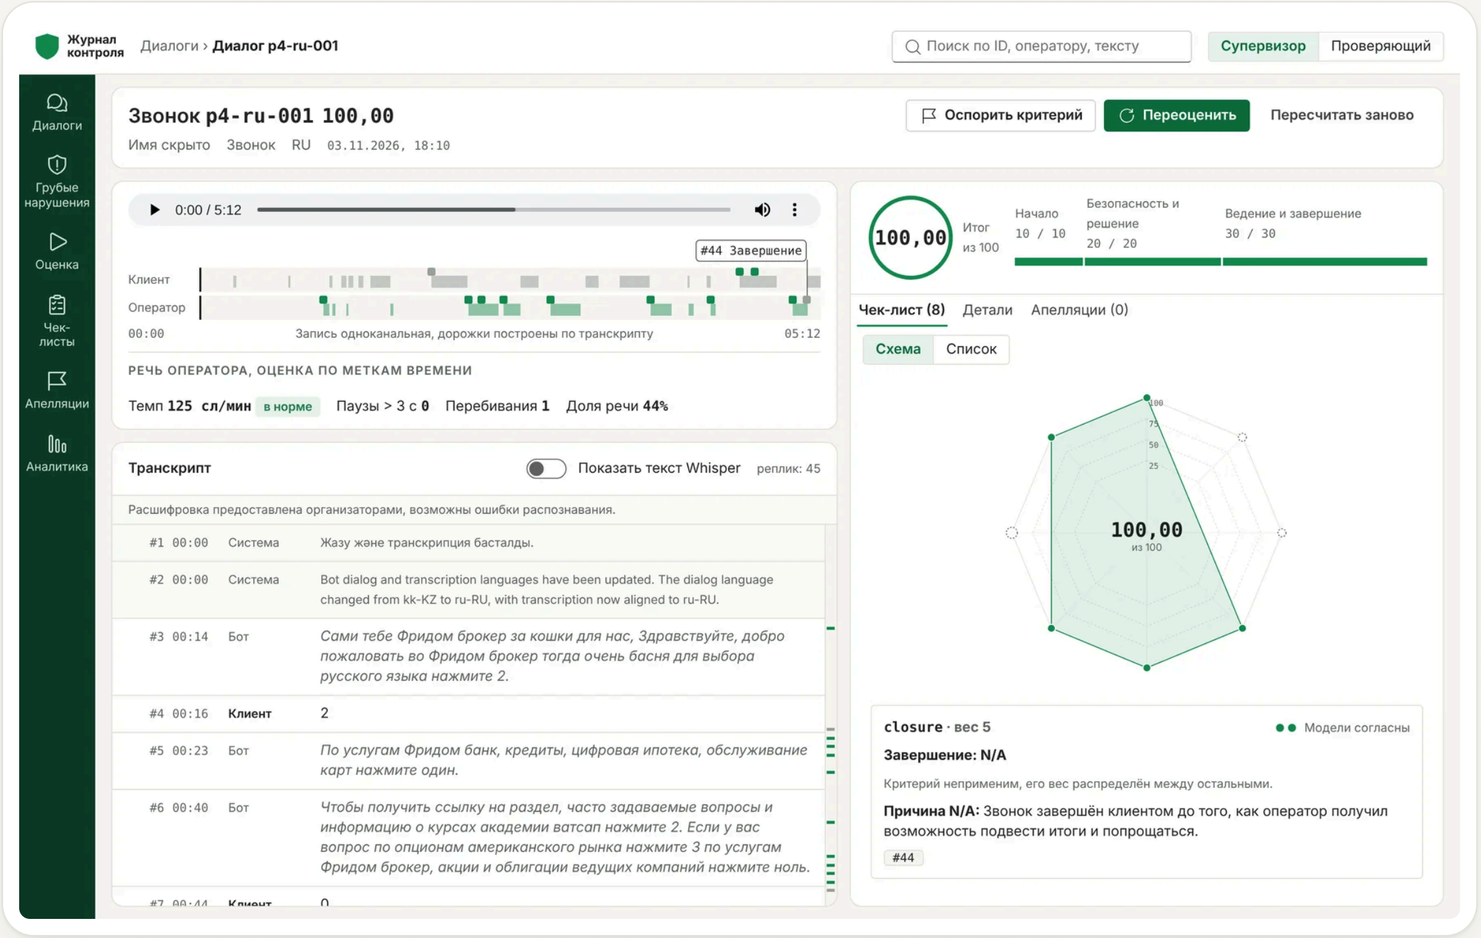

Дубли ASR

повторы распознавания убираются при нормализации

Маски данных

персональные данные скрыты до оценки

Локальный Whisper

запись не уходит наружу

резерв

N/A не равно нулю: ru-020

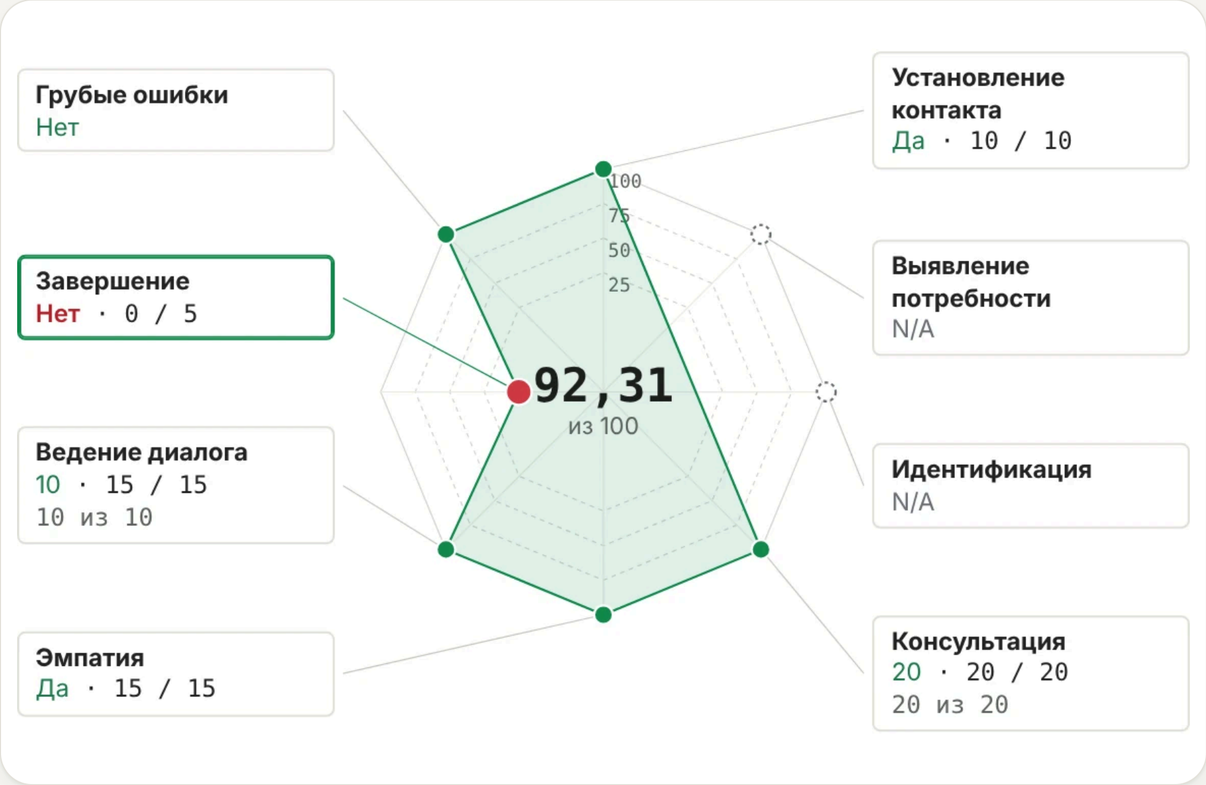

~~60~~ → **92,31**

если N/A считать нулём, было бы 60; вес N/A делят остальные критерии

Контакт	10	**Да**
Потребность	15	**N/A**
Идентификация	20	**N/A**
Консультация	20	**20 из 20**
Эмпатия	15	**Да**
Ведение	15	**10 из 10**
Завершение	5	**Нет**

применимо **65**, набрано **60**: 60 / 65 = **92,31**

резерв

Ограничения, честно

эталон

Эталон наш, а не Freedom

размечен нашей командой по чек-листу и трактовкам Freedom до запуска модели

контроль

Контроль: 10 чатов

71 уверенный пункт, 9 спорных исключены

c2

Потребность: 75%

6 из 8 на контроле: граница между «уточнил» и N/A

c7

Правило про прощание

Freedom: «на ваше усмотрение». Мы читаем чек-лист буквально: подвёл итог или предложил помощь и попрощался. От правила зависят 44 из 65 чатов

резерв

Апелляции и редактор чек-листа

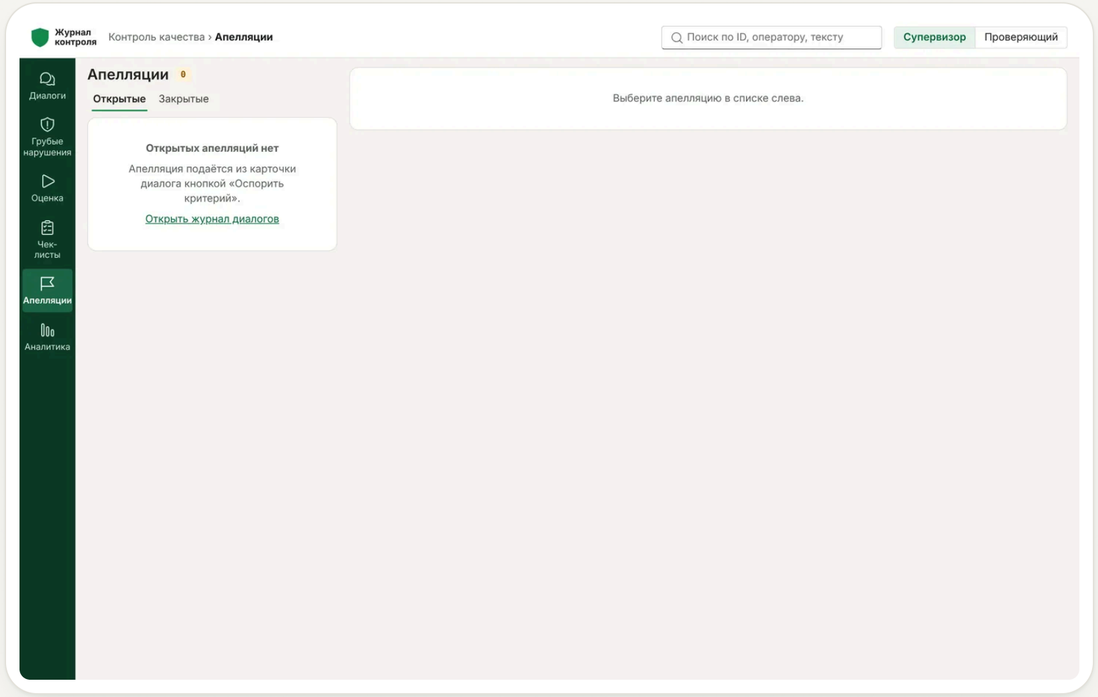

Апелляция: модель → решение → финал

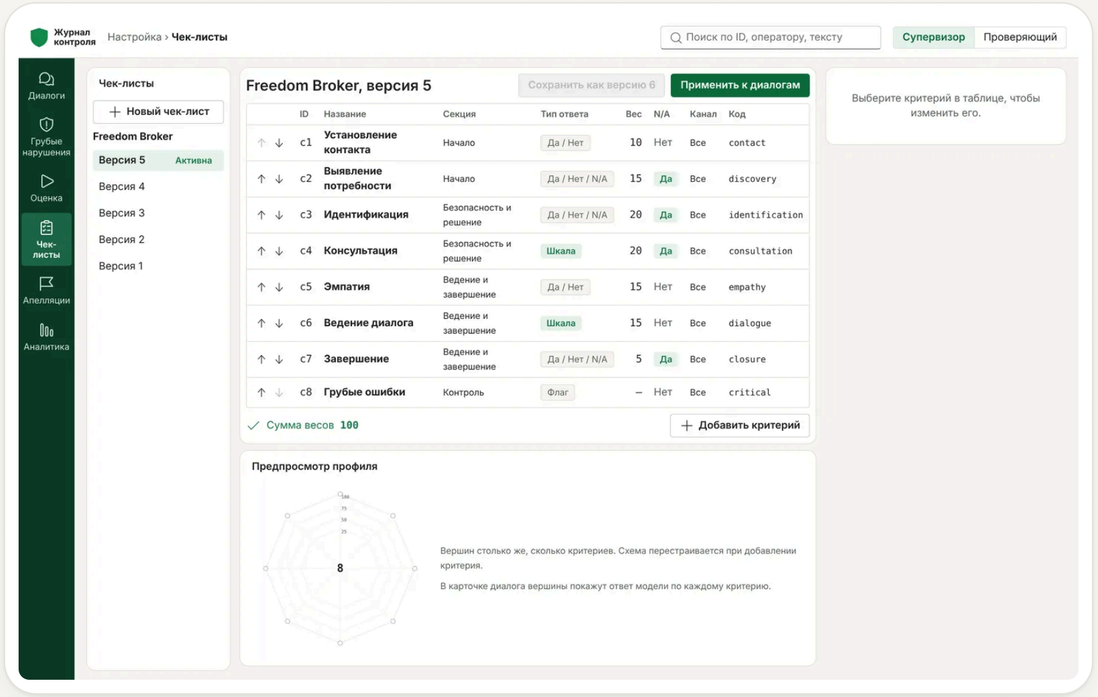

Чек-лист компилируется в промпт и JSON-схему: новый критерий без кода