Журнал контроля

Контроль качества чатов и звонков Freedom Broker

Каждый диалог, а не 3%

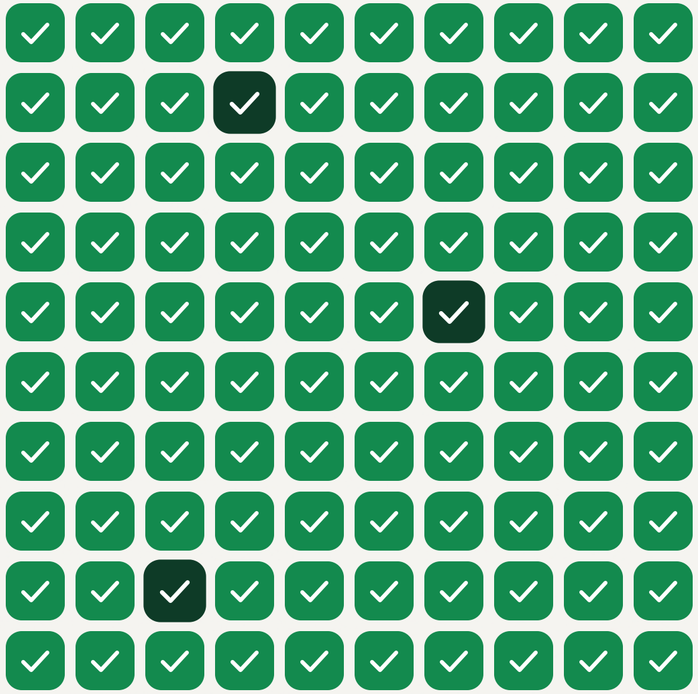

100%

оцениваем мы

Автооценка 100% диалогов за $0,021 на диалог.

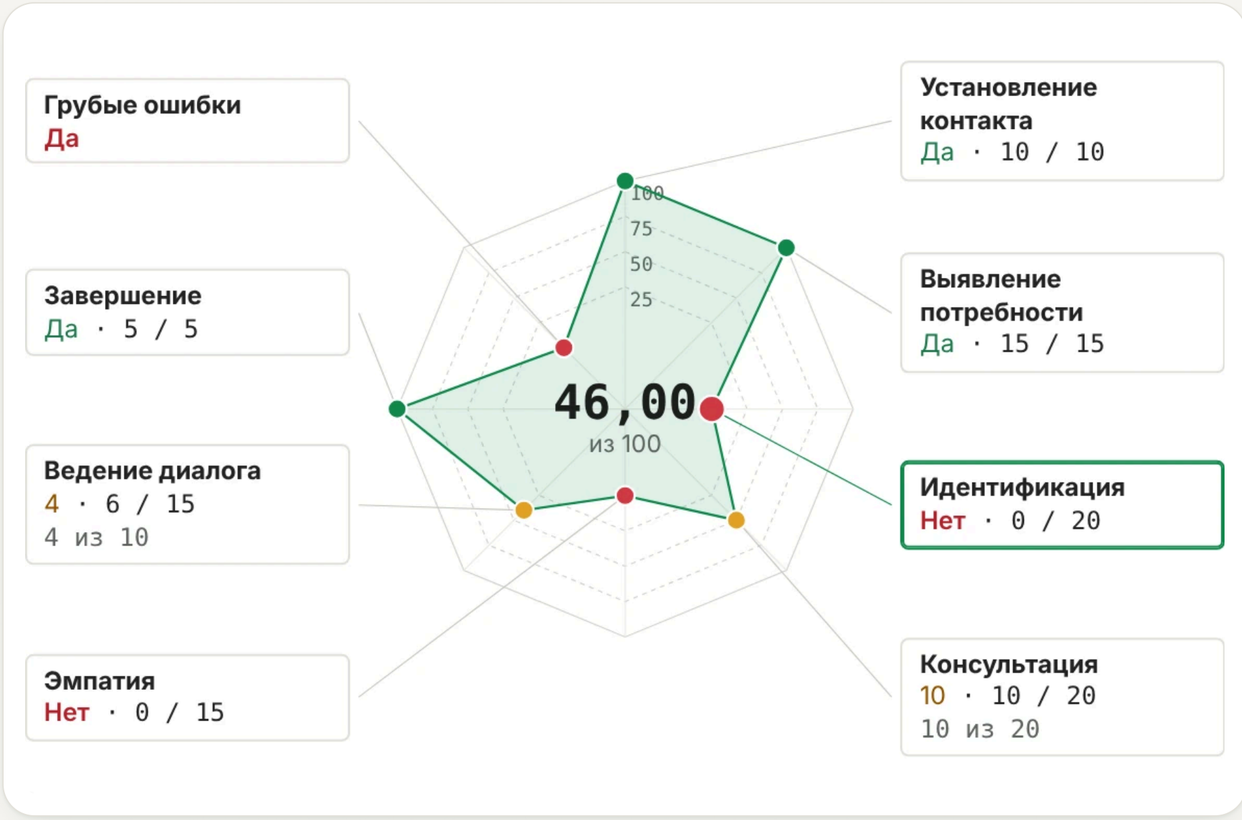

8 критериев, каждый с доказательством

На чём мы *стоим*

arXiv:2604.23178v2 — раздел 3.3, стратегия S5

Judging the Judges: A Systematic Evaluation of Bias Mitigation Strategies in LLM-as-a-Judge Pipelines

Sadman Kabir Soumik

Explicit step-by-step analysis required before the model emits the verdict field.

Сначала реплики и рассуждение, потом ответ

openlayer.com — 30.03.2026

LLM-as-judge: A complete guide to evaluation best practices in March 2026

Openlayer

cross-validate with a second model from a different provider

Судьи Gemini и GPT: два разных вендора

kili-technology.com — 16.10.2026

Who Judges the Judge? A Data Story on 541,000 LLM-Judge Decisions and an Annotator-Pool Audit

Kili Technology

consistent and wrong

Точность и стабильность меряем отдельно

arXiv:2602.08672 — аннотация

Learning to Judge: LLMs Designing and Applying Evaluation Rubrics

Siro, Aliannejadi, Aliannejadi

scoring reliability degrades in factual and knowledge-intensive settings

Не выдумывать факты о продуктах Freedom

Модель выбрали *турниром*

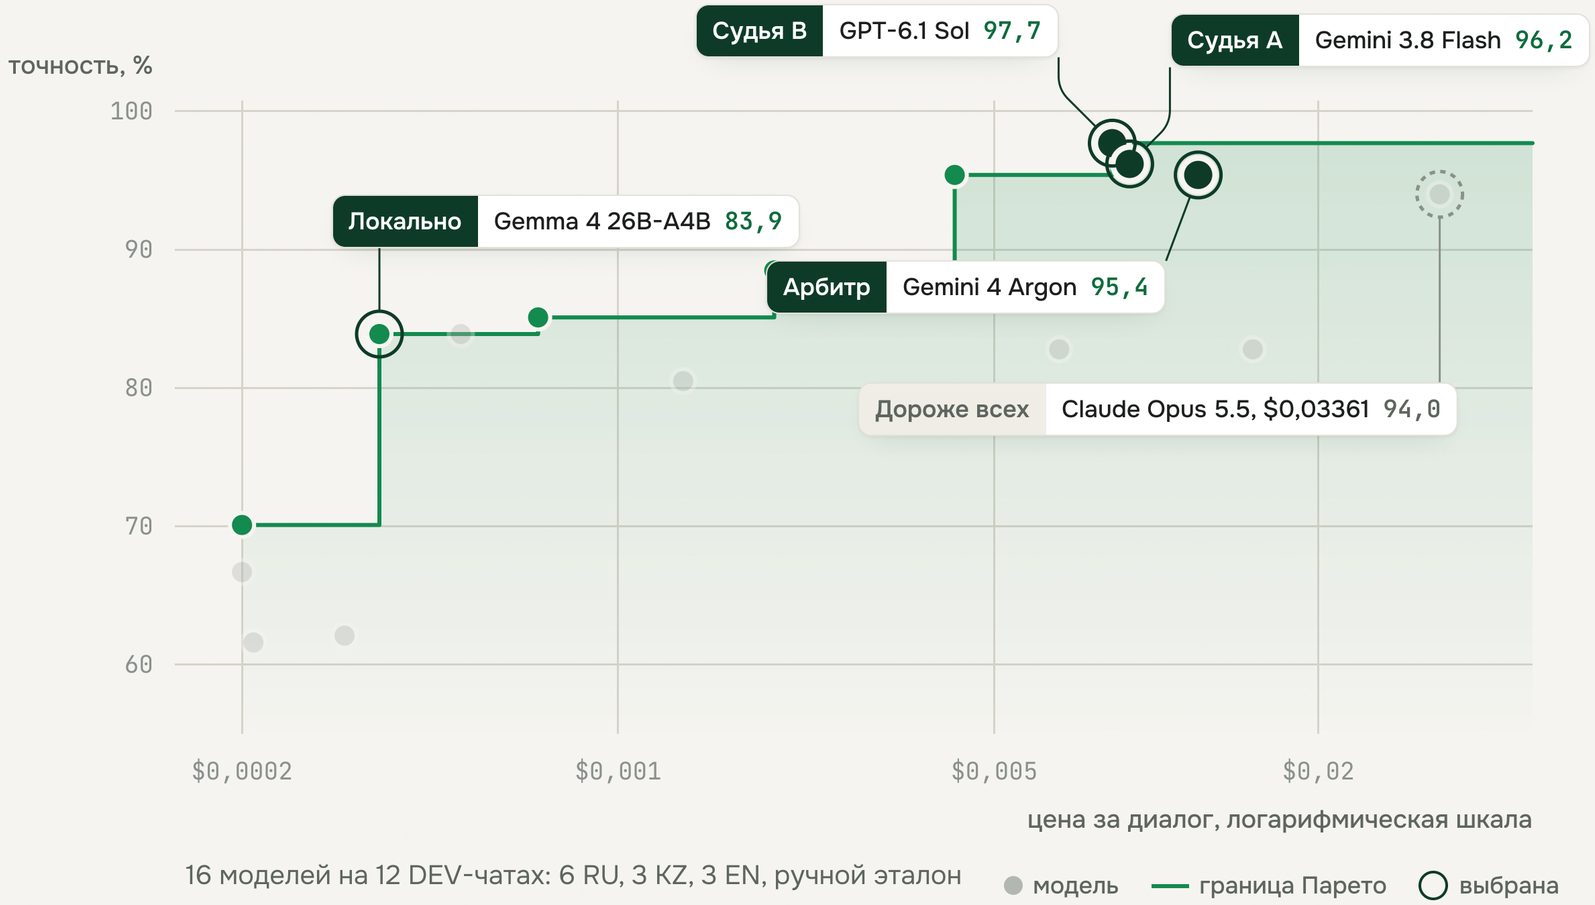

Топ-5 по точности

Модель	Всего	KZ
GPT-6.1 Sol Судья B	97,7	95
Gemini 3.8 Flash Судья A	96,2	100
GPT-6.1 Terra	95,4	100
Gemini 4 Argon Арбитр	95,4	95
Claude Opus 5.5	94,0	100

Два судьи и *арбитр*

3 Чек-лист → промпт: новый критерий без кода

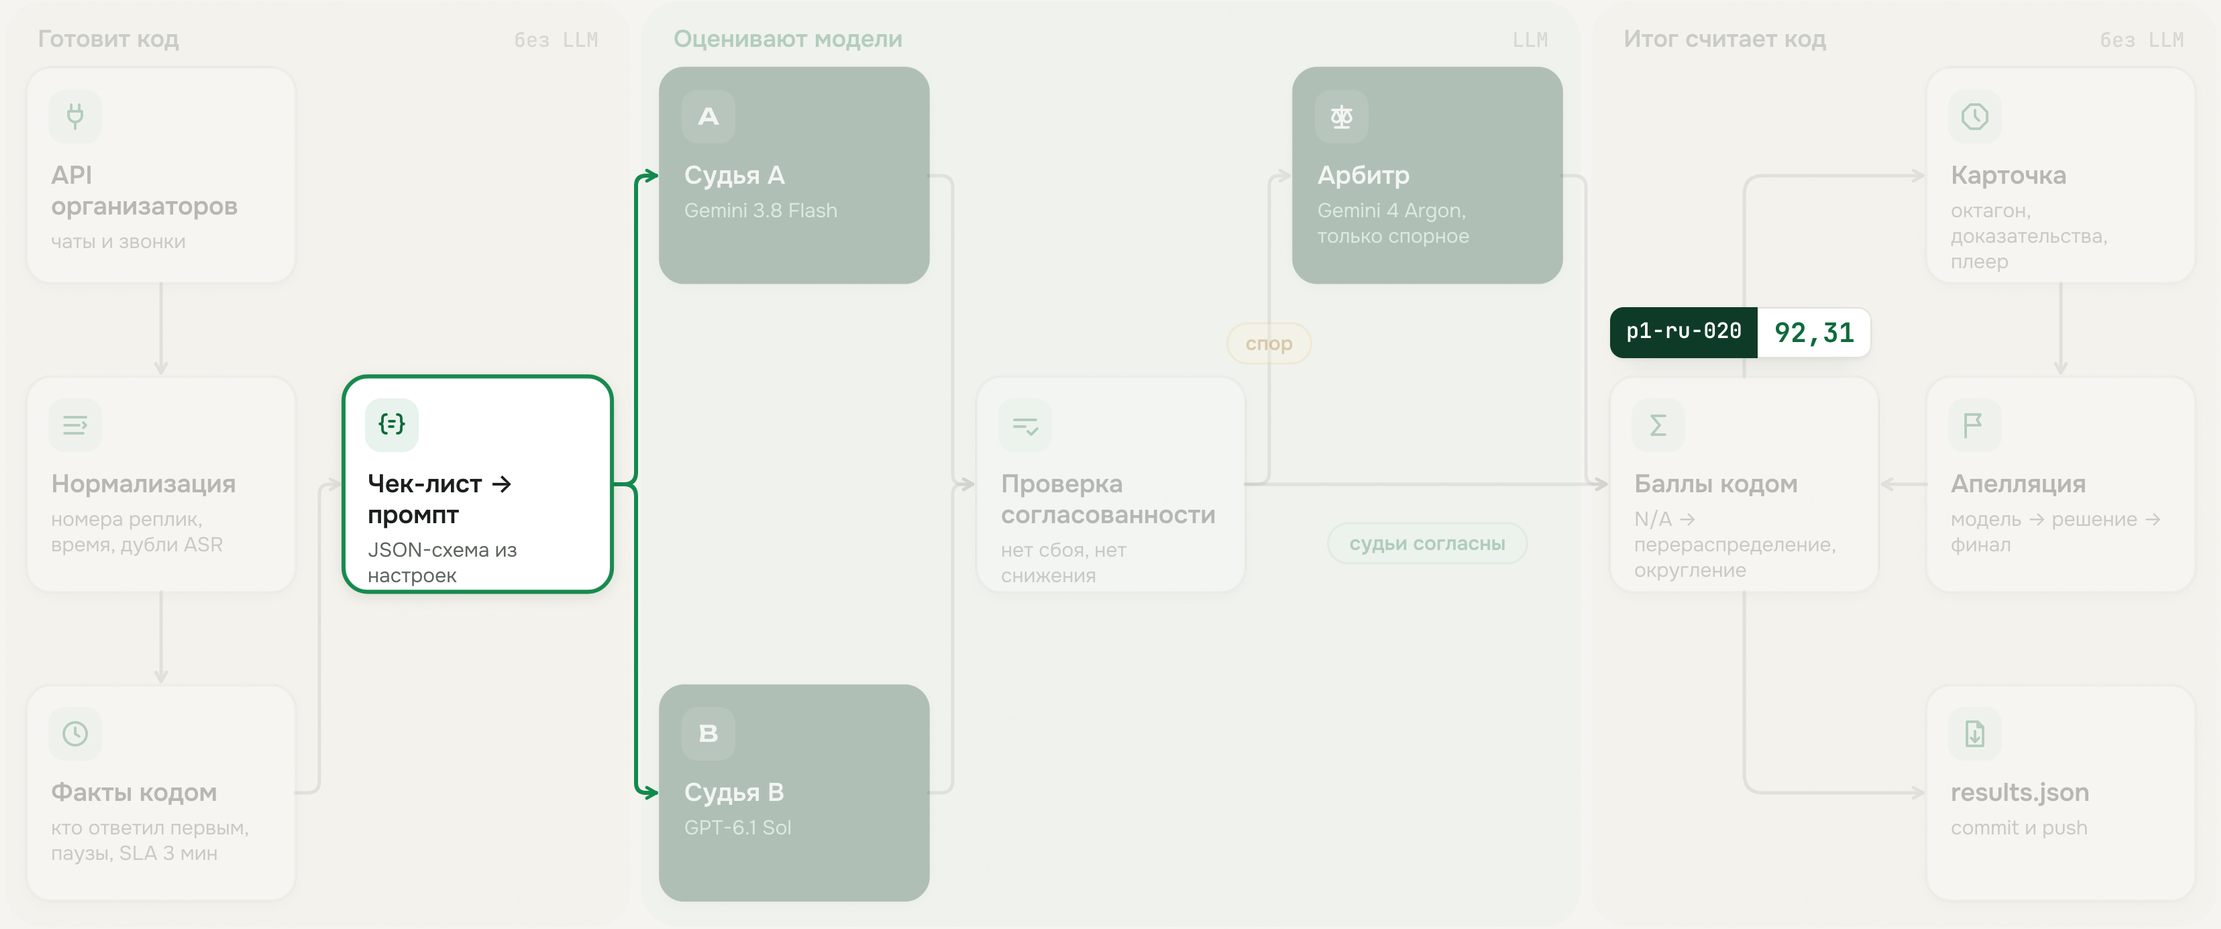

Где решается *точность*

трудно — клиент сразу всё сказал = N/A
трактовка Freedom

трудно — Хуже всего модели оценивают фактическую правильность
GER-Eval

трудно — только прощание = Нет
трактовка Freedom

Совпадение с эталоном по критерию, все 16 моделей, %

Что мы *подкрутили*

~~28~~

1

тише

Флаг «На проверку» только при реальном споре

Из 65 диалогов DEV.

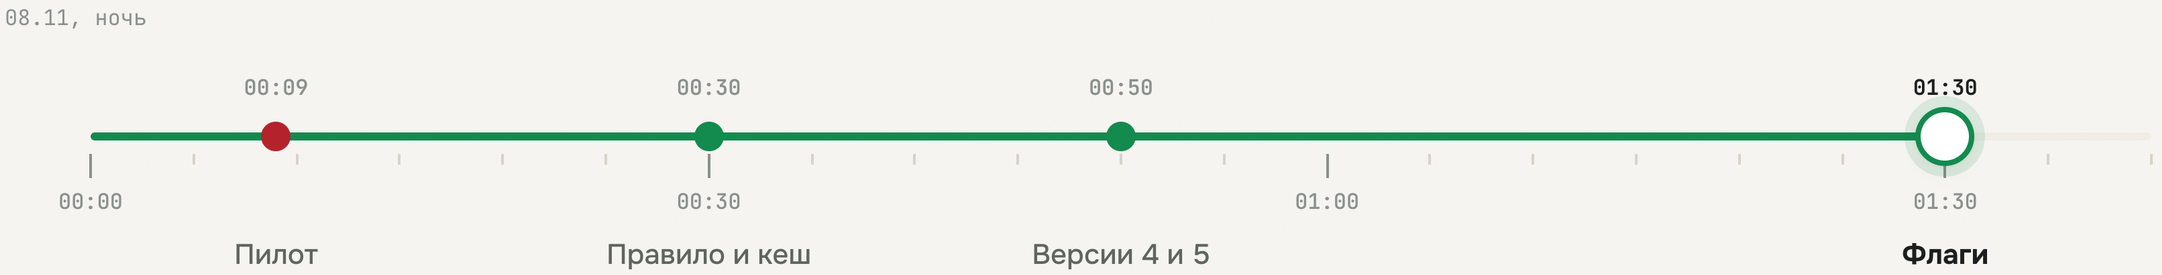

Демо

1. Грубые нарушения
2. Карточка `p1-ru-009`
3. Апелляция
4. Новый критерий и вес
5. Карта диалогов

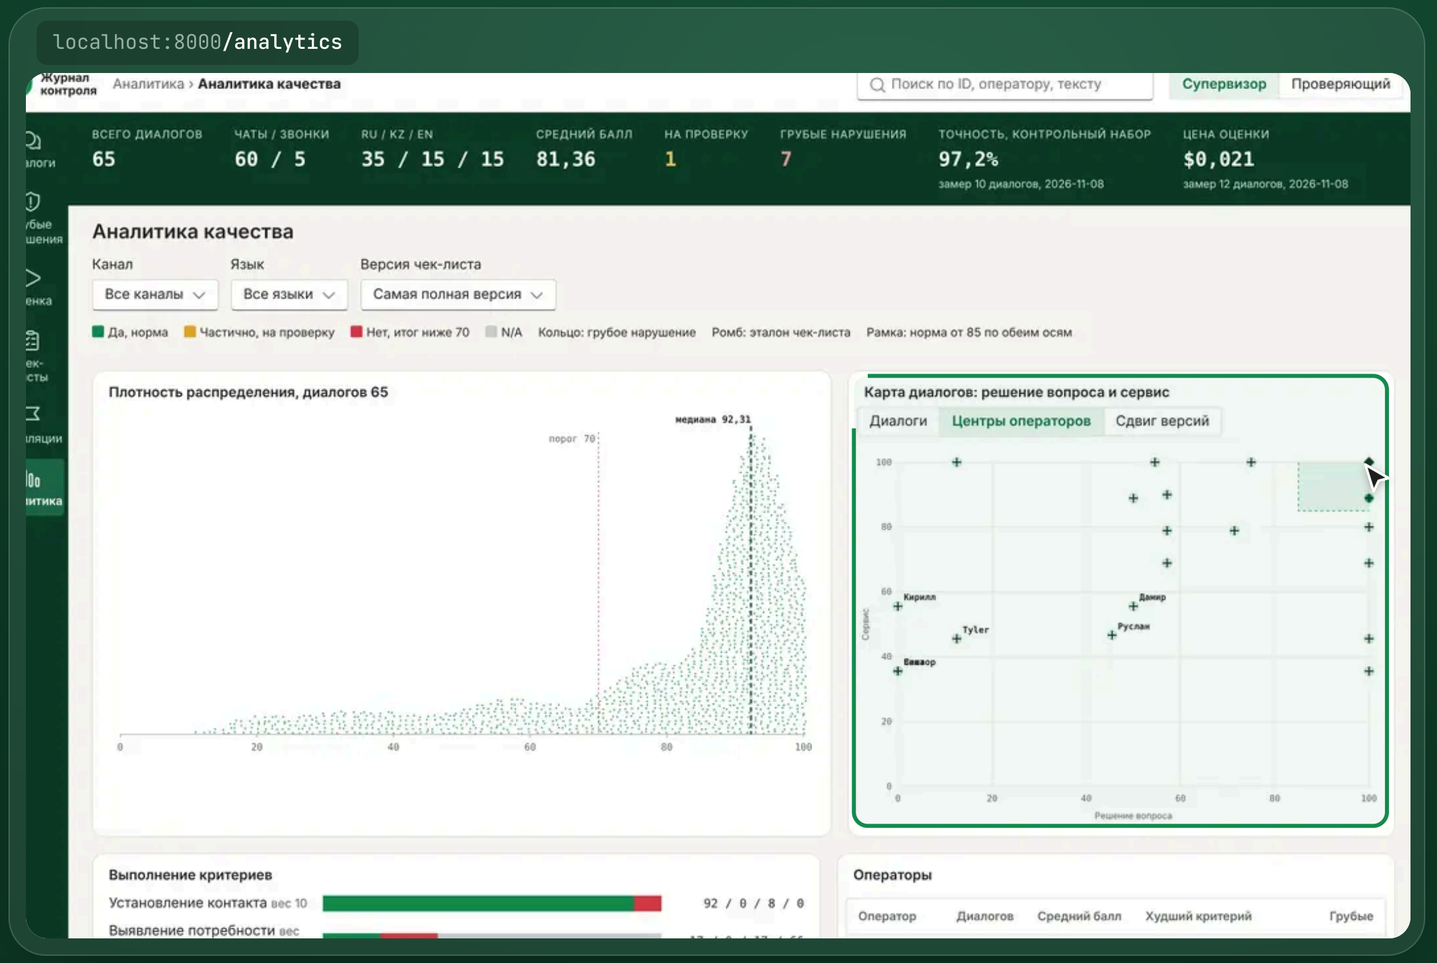

Результат на *новых* данных

точность на 10 новых чатах

97,2%

69 из 71 ответов, эталон до прогона

ошибка итога на них же

4,30

0 — 10 баллов

средняя разница с эталоном, из 100

стабильность повтора

99%

повтор даёт тот же ответ

цена за диалог

$0,021

наш ансамбль

Claude Opus 5.5

Claude Opus 5.5: $0,03361

65 диалогов DEV

RU KZ EN

96 из 96 тестов

Почему N/A не ноль

p1-ru-020

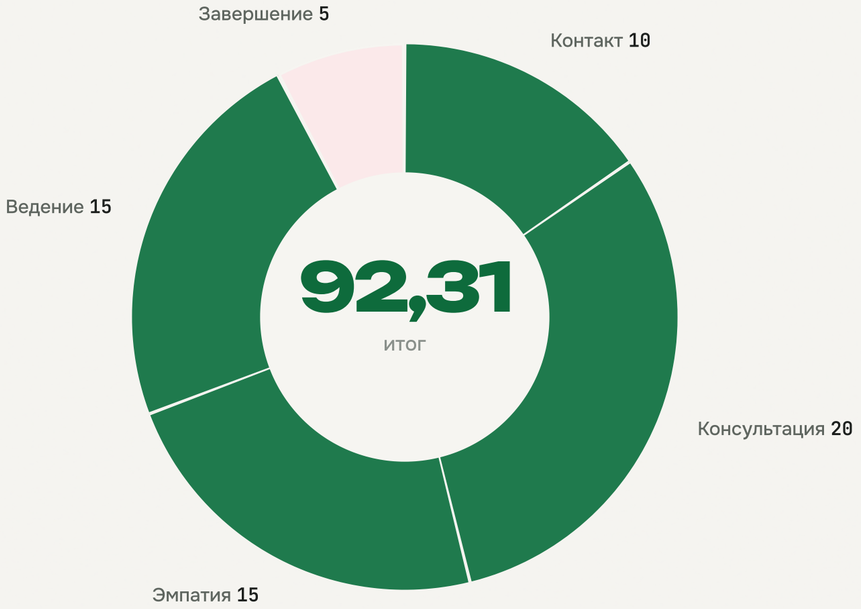

~~60~~ если считать N/A нулём. Вес «Потребность» и «Идентификация» делят остальные

Что сделали *сами*

Свой бенчмарк на 16 моделях

Выбор моделей по своему бенчмарку на 16 моделях, а не по рейтингам

Два судьи и арбитр

Два судьи разных вендоров и арбитр только по спорным критериям

Новый критерий без кода

Чек-лист компилируется в промпт и JSON-схему: новый критерий без кода

Нет сбоя, нет снижения

Правило «нет сбоя с номером реплики, нет снижения»

Эталон размечен до прогона

Контрольная выборка размечена до прогона

Звонки: маски и локальный Whisper

Звонки: дубли ASR, маски персональных данных, локальный Whisper

Что *дальше*

Справочник продуктов Freedom
чтобы «Консультация» проверяла факты, а не только логику

ASR и диаризация для звонков
две настоящие дорожки вместо восстановленных по транскрипту

Компонент Dynamics 365
оценка прямо в карточке обращения

github.com/GeorgeTolen/real-couple

Спасибо

с1 контакт · с2 потребность · с3 идентификация · с4 консультация · с5 эмпатия · с6 ведение · с7 завершение · с8 грубые ·

резерв

Звонки: две дорожки и маски

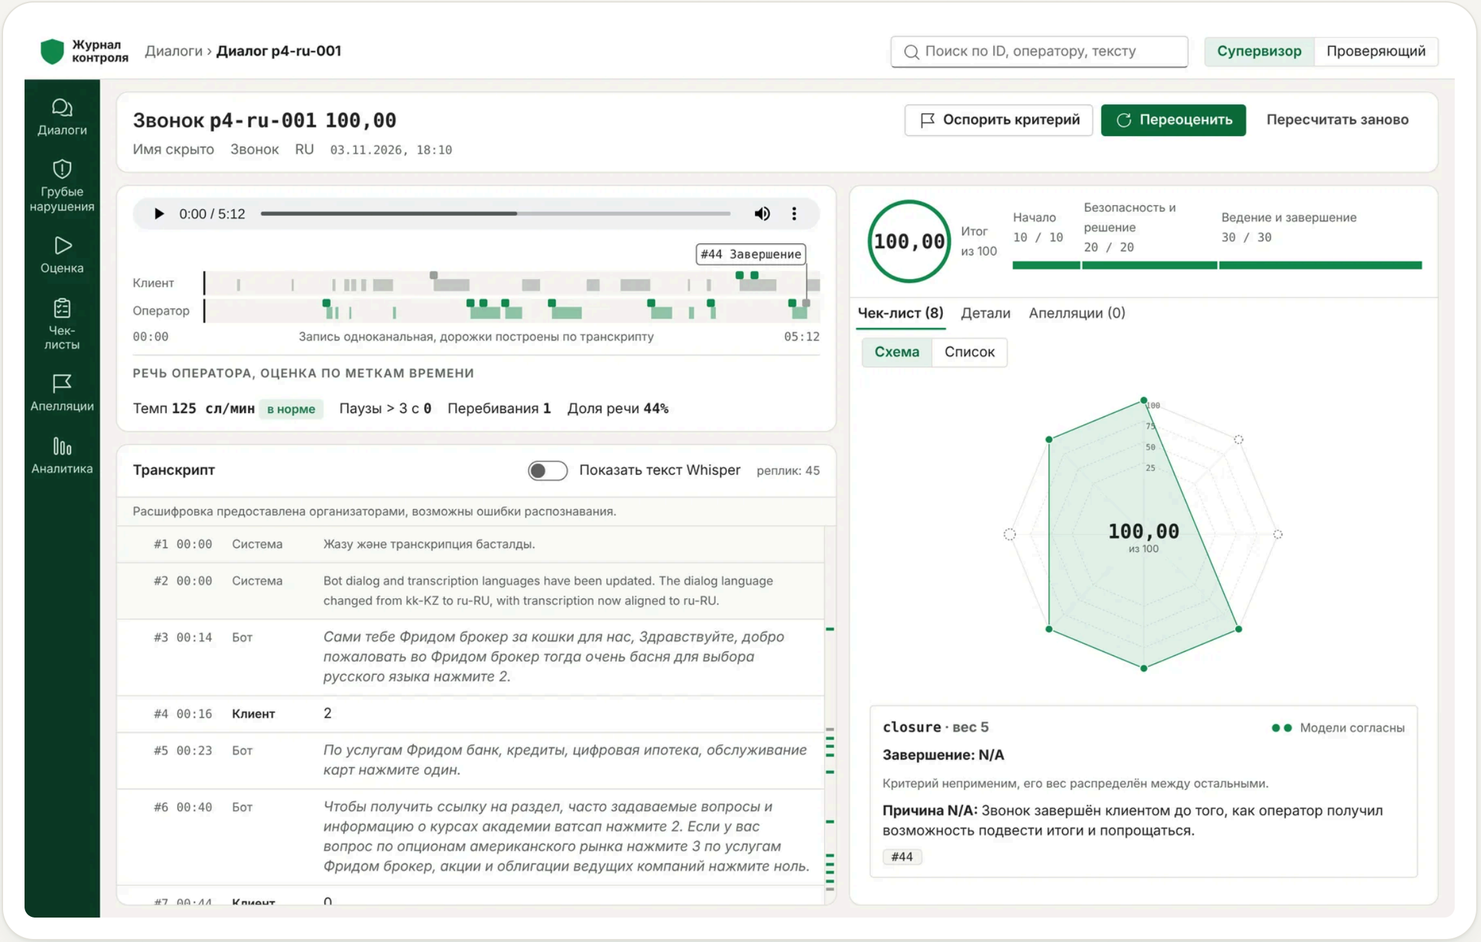

Две дорожки

запись одноканальная, дорожки построены по транскрипту

Метрики речи

темп, паузы, перебивания, доля речи по меткам времени

Маски данных

дубли ASR убраны, персональные данные скрыты, Whisper локально

резерв

Локальный режим

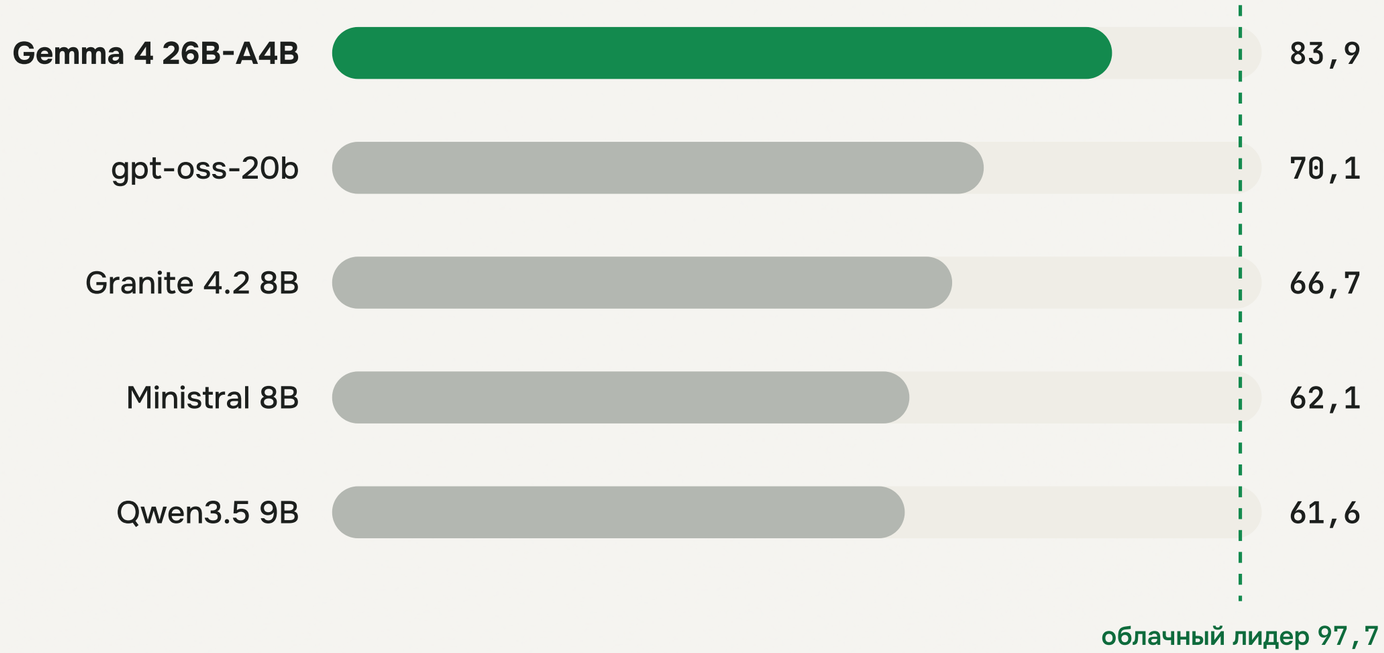

Модели, которые помещаются в ноутбук с 8 ГБ видеопамяти, точность на тех же 12 DEV-чатах, %

Тот же код, судья Gemma 4 26B-A4B через Ollama

Данные не покидают компьютер

Честная точность: 83,9%

Грубые нарушения: найдено 11 из 12, $0,00036 за диалог через OpenRouter

резерв

Все 16 моделей

Модель	Точность	RU	KZ	EN	Грубые	Ошибка итога	$ за диалог	с на диалог	Открытые веса	Роль
GPT-6.1 Sol	97,7	98	95	100	12/12	5,71	0,00828	9,2	нет	**Судья B**
Gemini 3.8 Flash	96,2	97	100	91	10/11	2,97	0,00892	15,9	нет	**Судья A**
GPT-6.1 Terra	95,4	93	100	96	12/12	9,58	0,00422	9,3	нет	
Gemini 4 Argon	95,4	98	95	91	12/12	4,86	0,01196	13,4	нет	**Арбитр**
Claude Opus 5.5	94,0	93	100	94	9/9	2,85	0,03361	13,9	нет	
DeepSeek V4.1 Flash	88,5	88	86	91	12/12	10,29	0,00195	13,7	да	
GPT-6 Luna	85,1	86	81	87	12/12	10,16	0,00071	14,3	нет	
GLM-5.3 Flash	83,9	79	81	96	12/12	8,83	0,00051	6	да	
Gemma 4 26B-A4B	83,9	88	81	78	11/12	11,18	0,00036	15	да	**Локально**
Claude Sonnet 5.5	82,8	81	81	87	11/12	11,22	0,01511	9	нет	
Qwen3.8 27B	82,8	81	76	91	12/12	16,27	0,0066	25	да	
Claude Haiku 5.5	80,5	81	81	78	12/12	14,80	0,00132	10,2	нет	
gpt-oss-20b	70,1	70	71	70	11/12	17,43	0,0002	8,2	да	
Granite 4.2 8B	66,7	63	62	78	10/12	16,60	0,0002	7,5	да	
Ministral 8B	62,1	67	52	61	10/12	24,20	0,00031	9,4	да	
Qwen3.5 9B	61,6	50	76	69	9/10	31,10	0,00021	157,5	да	

резерв

Что пока не проверено

контроль

Контрольные чаты наши

Эталон зафиксирован до прогона, но чаты писал автор системы, и они чище реальных

калибровка

Цифра завышена

98,9% на 12 диалогах, на которых настраивались подсказки

не запускали

Окружения

Docker, локальную модель и запуск на Linux

Настоящей проверкой будет эталон организаторов.